

# 机器学习导论

## 习题六

151242041, 王昊庭, hatsuyukiw@gmail.com

2017 年 6 月 9 日

### 1 [20pts] Ensemble Methods

- (1) [10pts] 试说明 Boosting 的核心思想是什么, Boosting 中什么操作使得基分类器具备多样性?
- (2) [10pts] 试析随机森林为何比决策树 Bagging 集成的训练速度更快。

**Solution.** (1) Boosting 的核心思想是先从初始训练集训练出一个基学习器, 之后根据基学习器的表现, 改变训练集, 使得后续的学习器可以将重点放在之前的学习器的偏差上. 改变训练集的主要方法有

- 改变样本分布, 使得之前的学习器分类错误或者误差较大的样本的概率增大, 使得后续分类器更加关注这类样本, 比如 AdaBoost 使用的就是这个方法
- 后续训练器在之前的学习器的误差上进行学习, 常见于回归模型

等.

- (2) 随机森林引入了属性随机选择的特性, 单个决策树考虑的属性减少, 速度自然比考虑全部属性的决策树更快. 故而在决策树数目相同的情况下, 随机森林比决策树 Bagging 集成的训练速度更快.

### 2 [20pts] Bagging

考虑一个回归学习任务  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ . 假设我们已经学得  $M$  个学习器  $\hat{f}_1(\mathbf{x}), \hat{f}_2(\mathbf{x}), \dots, \hat{f}_M(\mathbf{x})$ . 我们可以将学习器的预测值看作真实值项加上误差项

$$\hat{f}_m(\mathbf{x}) = f(\mathbf{x}) + \epsilon_m(\mathbf{x}) \quad (2.1)$$

每个学习器的期望平方误差为  $\mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})^2]$ . 所有的学习器的期望平方误差的平均值为

$$E_{av} = \frac{1}{M} \sum_{m=1}^M \mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})^2] \quad (2.2)$$

M 个学习器得到的 Bagging 模型为

$$\hat{f}_{bag}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M \hat{f}_m(\mathbf{x}) \quad (2.3)$$

Bagging 模型的误差为

$$\epsilon_{bag}(\mathbf{x}) = \hat{f}_{bag}(\mathbf{x}) - f(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M \epsilon_m(\mathbf{x}) \quad (2.4)$$

其期望平均误差为

$$E_{bag} = \mathbb{E}_{\mathbf{x}}[\epsilon_{bag}(\mathbf{x})^2] \quad (2.5)$$

(1) [10pts] 假设  $\forall m \neq l, \mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})] = 0, \mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})\epsilon_l(\mathbf{x})] = 0$ 。证明

$$E_{bag} = \frac{1}{M} E_{av} \quad (2.6)$$

(2) [10pts] 试证明不需对  $\epsilon_m(\mathbf{x})$  做任何假设,  $E_{bag} \leq E_{av}$  始终成立。(提示: 使用 Jensen's inequality)

**Proof.** (1)

$$\begin{aligned} E_{bag} &= \mathbb{E}_{\mathbf{x}}[\epsilon_{bag}(\mathbf{x})^2] \\ &= \frac{1}{M^2} \mathbb{E}_{\mathbf{x}}[(\sum_{m=1}^M \epsilon_m(\mathbf{x}))^2] \\ &= \frac{1}{M^2} \left( \sum_{i=1}^M \mathbb{E}_{\mathbf{x}}[(\epsilon_i(\mathbf{x}))^2] + \sum_{i=1, j=2, i \neq j}^M \mathbb{E}_{\mathbf{x}}[\epsilon_i(\mathbf{x})\epsilon_j(\mathbf{x})] \right) \\ &= \frac{1}{M} \left( \frac{1}{M} \sum_{i=1}^M \mathbb{E}_{\mathbf{x}}[(\epsilon_i(\mathbf{x}))^2] \right) \\ &= \frac{1}{M} E_{av} . \end{aligned}$$

(2) The function  $f(x) = x^2$  is convex. Thus Jensen's inequality  $f(\frac{1}{N} \sum_{i=1}^N x_i) \leq \sum_{i=1}^N \frac{1}{N} f(x_i)$  holds.

$$\begin{aligned} E_{bag} &= \mathbb{E}_{\mathbf{x}}[\epsilon_{bag}(\mathbf{x})^2] \\ &= \frac{1}{M} \mathbb{E}_{\mathbf{x}}[M(\frac{1}{M} \sum_{m=1}^M \epsilon_m(\mathbf{x}))^2] \\ &\leq \frac{1}{M} \mathbb{E}_{\mathbf{x}}[\sum_{m=1}^M (\epsilon_m(\mathbf{x}))^2] \\ &= \frac{1}{M} \sum_{m=1}^M \mathbb{E}_{\mathbf{x}}[(\epsilon_m(\mathbf{x}))^2] \\ &= E_{av} . \end{aligned}$$

□

### 3 [30pts] AdaBoost in Practice

- (1) [25pts] 请实现以 Logistic Regression 为基分类器的 AdaBoost, 观察不同数量的 ensemble 带来的影响。详细编程题指南请参见链接：[http://lamda.nju.edu.cn/ml2017/PS6/ML6\\_programming.html](http://lamda.nju.edu.cn/ml2017/PS6/ML6_programming.html)
- (2) [5pts] 在完成上述实践任务之后, 你对 AdaBoost 算法有什么新的认识吗? 请简要谈谈。

**Solution.** 这个作者认为本题的算法在理论上是无意义的, 在实践中是错误的.

LR 的本质是给出一个空间中的超平面划分, AdaBoost 将若干个分类器线性组合, 故而 LR AdaBoost 的最终决策界仍然是空间中的超平面. 也就是说 LR AdaBoost 的假设空间位于单个 LR 的假设空间内, 故而单个 LR 最优假设优于或等于 LR AdaBoost 最优假设.

在无正则项的情形下, 由于 LR 是凸优化问题, 很容易得到 LR 的假设空间中的这个最优假设. 另一方面, AdaBoost 或许可以视为一种正则, 但是从实验来看 LR 的 L2 regularization 完全优于 AdaBoost 的正则 (这个作者认为在 LR 上 AdaBoost 实际没有正则的效果).

总之, 无论是从理论还是从实践的角度分析, LR AdaBoost 都完全没有意义.